

Datos Masivos

Reporte de análisis con MLib del conjunto de datos

Descripción del conjunto de datos

El conjunto de datos a utilizar es información extraída mediante la API de YouTube, la cual corresponde a comentarios e interacciones en los comentarios de diferentes canales de YouTube en 10 videos seleccionados de manera aleatoria, con una gran escala de temáticas tanto en videos como en canales.

Los canales de los cuales se realizaron las extracciones de datos son:

- Luisito Comunica
- Conversaciones
- El Rincon de Giorgio
- Mi Querido Mussolini
- Zazza El Italiano
- Lethal Crysis
- Relatos Forenses Podcast
- HiClavero
- Eva Maria Beristain
- Alex Tienda
- Ibai
- Slobotzky
- Adrian Marcelo
- Doble G

Con esos 15 canales obtuvimos una gran cantidad de comentarios, interacciones, horas de creación, usuarios que representan distintas comunidades y puntos de vista. La mejor manera de analizar este tipo de información es justamente con las extracciones aleatorias que se realizaron, pues de manera aleatoria se estarían obteniendo muestras de comunidades sin un orden como tal, sin una jerarquía ni de popularidad ni de alguna región en específico.

La data específicamente obtenida de las consultas a la API de Youtube es la siguiente:


Variable/Dato	Ejemplo
Channel_id	UCaY_-ksFSQtTGk0y1HA_3YQ
Channel_title	Ibai
Video_id	9Bk4cycSqRo
Video_title	Tremendos bombazos que pegan Viruzz y Gero
Author	@Lokeraar10
Comment	El video más esperado de esa máquina de feria
Likes	0
Published_at	2026-03-28T19:29:12Z
Reply_count	0

Objetivo del análisis


El objetivo de este análisis es la clasificación de distintos tipos de comentarios para clasificarlos en diferentes clusters para comentarios con características distintas, como aquellos con nulas interacciones, otros con interacciones denominadas como “virales”, comentarios muy cortos y reactivos como emojis o simples risas escritas, o comentarios muy largos que incluyan vivencias o experiencias personales, entre distintas características. Esto para poder tener un mapeo de los tipos de comentarios disponibles, el comportamiento de las comunidades y las interacciones que ocurren en las mismas.

Análisis exploratorio de los datos

Realizando este análisis de exploratorio de manera más visual, primero atacaremos el comportamiento de los likes en los comentarios, pero agrupados a un nivel por canal.





Distribución de likes de los 6 canales mas importantes (con mas interacciones)



Lo que obtenemos de ver el promedio y distribución de likes, es identificar los canales donde más interacción suele existir en las comunidades, observando que no necesariamente aquellos canales con un mayor promedio de likes suelen tener una distribución más amplia o una mayor cantidad de las mismas.

Ahora centrándonos en los comentarios per se, obviando las interacciones.



Obtenemos e inferimos ciertas características por canal, vemos que Eva María Beristain cuenta con una comunidad que suele tener en promedio una mayor longitud de caracteres en sus comentarios, pero la cantidad de comentarios que se extrajeron de 20 videos aleatorios, en realidad son pocos, comparados con otros canales con más de 10 mil comentarios extraídos.

Factores como el anteriormente mencionado nos pueden decir y explicar ciertos aspectos curiosos, pues la temática del canal de Eva María son temas de sociología e inclusive tocando lo polémico, mientras que el Rincón de Giorgio es un canal con un giro más de 'true crime' y cuenta con una cantidad de comentarios muy alta, lo cual nos podría explicar lo reactiva que es la comunidad cuando se tratan temas delicados o que generan morbo.

Análisis con MLib de PySpark

Para el análisis de los comentarios mediante MLib de PySpark, primero se realizó el pre procesamiento de la información, limpiando imperfecciones del texto, así como generando nuevas columnas construidas con base a las columnas del dataset extraído.

Generamos las columnas:

- ✓ Longitud_caracteres: se extrajo la longitud del comentario escrito y se imprimió en una columna nueva
- ✓ Popularidad: se generó una clasificación con base a los likes del comentario (Obviaremos esta columna pues no nos aportara mucho en este análisis)
- ✓ Fecha_limpia: se extrajo la fecha en formato limpio pues la columna original estaba en timestamp
- ✓ Hora_publicacion: Se extrajo la hora limpia de creación del comentario


Despues se limpió el texto contenido en la columna comment de manera que se pudiera realizar lo siguiente:

- Separación en palabras de los comentarios
- Conversión del texto a vectores numéricos mediante el método TF-IDF, representando la importancia de cada palabra en los comentarios

Después seleccionamos variables numéricas relevantes, que realmente aportaran al análisis que se buscaba hacer (K-Means) como:

1. Número de likes (likes)
2. Número de respuestas (reply_count)
3. Longitud del comentario (longitud_caracteres)
4. Hora de publicación del comentario (hora_publicacion)

Se buscaba aplicar el algoritmo de K-Means, para agrupar los comentarios en clusters. Por lo que, para determinar el número de clusters aplicamos el método del codo:



Lo que podemos apreciar es que aunque podríamos tomar $K=3$ pues ahí es cuando comienza la caída en el gráfico, tomaremos $K=4$ pues es a partir de ese punto donde la caída comienza a estabilizarse más, a caer de manera menos agresiva/pronunciada (comparado contra $K=3$).

K-Means nos permitio segmentar los comentarios en cuatro clusters con características diferenciadas, tanto en contenido del comentario como en nivel de interacción.

Los clusters generados son los siguientes:

- Cluster 0: Comentarios simples con nulas o muy pocas interacciones. Generalmente son respuestas cortas y de bajo impacto, suelen ser comentarios muy reaccionarios como risas escritas o pequeños comentarios

Ejemplo	Likes	Longitud
sácate la papa de la boca mijooo	0	32
de donde es gonzalo?	0	20
mañana nuevo capitulo de conversaciones	0	39

- Cluster 1: Comentarios con contenido aleatorio pero que presentan altos niveles de interacción, considerados como comentarios virales.

Ejemplo	Likes	Longitud
se acordó de la contraseña del canal	37685	36
se acordó de la contraseña del canal	45738	36
jordi es como mi papa, se va por meses y regresa para traumarme	45648	63

- Cluster 2: Comentarios elaborados y estructurados, que además reciben una cantidad significativa de likes, indicando alta relevancia.

Ejemplo	Likes	Longitud
trabaje en un lugar donde vendía perfumes *clones, olían igual incluso los envases llegan a ser idénticos la diferencia es la duración del olor del perfume. que buen contenido mi estimado luisillo. 🙌 posdata: mi hijo de 6 años es tu fan 😊	10892	239
ver a giorgio con canas en la barba me hace ver que a pasado demasiado tiempo	20542	77

jordi, hermano mío, no nos abandones, muchos extrañamos este canal.	22799	67
---	-------	----


- Cluster 3: Comentarios largos y detallados, pero con pocas interacciones, lo que sugiere contenido elaborado pero con bajo impacto en la audiencia.

Ejemplo	Likes	Longitud
todo ser humano tiene derecho a habitar donde le plazca y que le dejen en paz, y este tiene la obligación de respetar la vida, los bienes y la libertad de los demás individuos. \n\nuno no tiene la culpa de haber nacido en el cerro, ni de tener más o menos melanina en la piel, tampoco escogió la lengua y la cultura en la que se desarrolló, pero puede aprender e incluso adoptar la cultura que más le plazca si eso lo hace feliz.\n\nla migración es algo natural del ser humano, latam debería de entenderlo bastante bien, ya que somos un tutti-frutti de europeos, indígenas, asiáticos y africanos 😊	0	596
es triste ver tantos comentarios críticos hacia otra cultura, simplemente por la percepción del olor. Canadá está aceptando a los indios como residentes permanentes, tienen sus razones para hacerlo. es sabido que, con la natalidad actual de Canadá tendrá problemas con el pago de pensiones en el futuro entre otros problemas, la contribución de estas personas es vital para garantizar el futuro de los canadienses. además el concepto de 'mal olor' es subjetivo y relativo; lo que algunos perciben como tal, para otros es simplemente parte de su cultura. en un país multicultural, debemos aprender a respetar y tolerar las diferencias culturales. si no te gusta, simplemente debes aceptarlo como parte de vivir en una sociedad diversa.	0	740


vivo en Canadá y puedo confirmar que cada vez es peor, y lo peor de todo es que huelen horrible (personas que jamás han estado en Canadá abstenganse de insultar, no lo han vivido), además hacen los ambientes de trabajo extremadamente tóxicos, manejan super mal por lo que siempre hay accidentes de auto y hacen que la experiencia de vivir en este país sea cada vez peor, definitivamente Canadá es India 2.0 y va encaminado a convertirse en un país de 3er mundo	0	460
--	---	-----

Nota: El resto de ejemplos se pueden apreciar en el código del análisis pues los ejemplos, o la gran mayoría si son muy largos.

Adicionalmente, genere las siguientes vistas con los clusters generados, para que sea más fácil visualizar los resultados.




Notamos como la longitud más grande se encuentra en el cluster 3, pero en ese mismo los Likes en promedio son demasiado bajos, así como el contraste con el cluster 1.



Quería poner un boxplot en el reporte, así que genere este de la distribución de likes por cluster, el cual nos muestra de una mejor manera como se componen los likes en los clusters.

Adicionalmente podemos ver gráficamente el comportamiento de las interacciones por hora de publicación, observamos perfectamente como los comentarios suelen generar mayores interacciones cuando se publican entre las 15:00 y las 16:00. No es una regla perfecta pero a manera general, en los 15 canales analizados, si realizas un comentario entre esas horas tienes más probabilidades de tener mayores interacciones (likes/viralidad).



Concluyendo

Este análisis permitió identificar una relación entre la longitud de los comentarios y su nivel de interacción. En pocos casos, los comentarios más elaborados tienden a generar mayor viralidad, mientras que otros, a pesar de su corta longitud, logran captar la atención de muchos usuarios.

Asimismo, se detectaron algunos casos atípicos de comentarios virales que, aun siendo simples o muy aleatorios, logran altos niveles de interacción, lo cual sugiere que la relevancia no depende únicamente de la complejidad del contenido.

También se pudieron identificar patrones fuera de los antes mencionados, a partir de la hora de publicación de los comentarios, un patrón interesante que responde a cotidianidad de la rutina de muchos usuarios de Youtube, como el estar más activos por las tardes, o el generar reacciones en horas fuera de horarios productivos.